



Universidad
Francisco de
Vitoria

UFV Madrid

UNIVERSIDAD FRANCISCO DE VITORIA

ESCUELA POLITÉCNICA SUPERIOR

GRADO EN INGENIERÍA INFORMÁTICA

Practica 01 - SOM

Equipo 3B-02

[Luis Sánchez Agulla | Javier Argenta Cañas | Miguel Ciordia Isac | Ana González Núñez]
Convocatoria de [2025] [2026]

Resumen

El trabajo aplica una técnica de mapas autoorganizados (SOM) para clasificar un total de 167 países a partir de 9 indicadores demográficos, económicos y de desarrollo. Tras analizar el dataset y después de un preprocesamiento con RobustScaler, para gestionar los valores atípicos, la diferencia de escala entre las variables entrenamos múltiples configuraciones SOM variando tanto las dimensiones, la topología y la tasa de aprendizaje- EL modelo más optimo después de un estudio exhaustivo es el 6x6 con tasa de aprendizaje del 0.5 y 2000 iteraciones, que equilibra el error de cuantización, el error topográfico y la distribución de neuronas activas. El análisis del modelo resultante permitió identificar 5 grupos de países con perfiles socioeconómicos diferenciados desde países en situación precaria hasta economías de Primer Mundo, evaluar los indicadores clave que impulsan cada clúster, y detectar valores atípicos como Luxemburgo, Singapur, Qatar y Nigeria por sus características económicas o demográficas excepcionales.

Tabla de contenidos

1. Introducción	4
2. Preparación del entorno	4
Descripción de los métodos utilizados para la limpieza de datos, preprocesamiento y visualización.....	5
Detección de valores atípicos	5
Distribuciones individuales.....	5
Relaciones entre variables	5
Correlaciones clave	6
Necesidad del escalado	6
Método de escalado aplicado	7
Dataset resultante	7
3. Implementación.....	7
4. Evaluación.....	9
4.1 Identificar los grupos que aparecen en el modelo, describirlos y marcarlos en el mapa de activación.	9
4.2. Evaluar qué indicadores demográficos, económicos, geográficos y/o de desarrollo son los principales impulsores detrás de la formación de estos clústeres.....	10
4.4. Clasificar las siguientes instancias	12
4.4.1. ¿Por qué están posicionados más lejos o más cerca de los centros de los grupos en los que fueron clasificados?	13
4.4.2. ¿Cómo se relacionan con los grupos circundantes en términos de proximidad topológica?	14
4.4.3. ¿Cuál crees que debería ser el criterio de agrupamiento representado por el mapa?	15
4.4.4. Identificar los países que aparecen como valores atípicos o que están posicionados en las regiones más aisladas del mapa.	15
5. Conclusiones.....	17
6. Referencias	18

1. Introducción

El propósito de este trabajo práctico es aplicar la técnica de Mapas Autoorganizados (SOM) al análisis y clasificación de países a escala mundial, buscando identificar patrones y agrupaciones naturales a partir de indicadores demográficos, económicos y de desarrollo.

El trabajo se estructura en torno a tres objetivos, utilizando un dataset de 167 países con 9 indicadores cuantitativos: en primer lugar, preparar y comprender el conjunto de datos, identificando las características relevantes y las transformaciones necesarias para el entrenamiento de la red; en segundo lugar, implementar y comparar múltiples configuraciones de SOM variando hiperparámetros y topologías para determinar el modelo óptimo; y en tercer lugar, evaluar el modelo resultante mediante métricas de error, mapas de activación y distancia, y análisis de los clústeres obtenidos para extraer conclusiones sobre la realidad socioeconómica de los países.

Para alcanzar estos objetivos se lleva a cabo un análisis exploratorio del dataset, un preprocesamiento centrado en el escalado de variables y la detección de valores atípicos, y una fase de experimentación sistemática con la librería MiniSom, evaluando los resultados a través de errores de cuantificación y topográfico, U-Matrix y visualizaciones complementarias con Plotly.

2. Preparación del entorno

El conjunto de datos utilizado para este trabajo proviene del fichero `world_data.csv`, el cual proporciona información de países de todo el mundo a través de diversos indicadores demográficos, económicos y de desarrollo.

El dataset este compuesto por 167 instancias, cada una representando un país, y 10 variables. De estas, una única variable es categórica (Country), que actúa como identificador del país, mientras que los 9 restantes son numéricos y describen distintas dimensiones de cada país:

- `child_mort`: tasa de mortalidad infantil (muertes por cada 1.000 nacidos vivos).
- `exports`: exportaciones de bienes y servicios como porcentaje del PIB.
- `health`: gasto total en salud como porcentaje del PIB.
- `imports`: importaciones de bienes y servicios como porcentaje del PIB.
- `income`: ingreso neto per cápita.
- `inflation`: tasa de inflación anual (medida del índice de precios al consumo).
- `life_expec`: esperanza de vida al nacer (en años).
- `total_fer`: tasa de fertilidad (número medio de hijos por mujer).

- **gdpp**: producto interior bruto per cápita (en dólares).

	child_mort	exports	health	imports	income	inflation	life_expec	total_fer	gdpp
count	167.000000	167.000000	167.000000	167.000000	167.000000	167.000000	167.000000	167.000000	167.000000
mean	38.270060	41.108976	6.815689	46.890215	17144.688623	7.781832	70.555689	2.947964	12964.155689
std	40.328931	27.412010	2.746837	24.209589	19278.067698	10.570704	8.893172	1.513848	18328.704809
min	2.600000	0.109000	1.810000	0.065900	609.000000	-4.210000	32.100000	1.150000	231.000000
25%	8.250000	23.800000	4.920000	30.200000	3355.000000	1.810000	65.300000	1.795000	1330.000000
50%	19.300000	35.000000	6.320000	43.300000	9960.000000	5.390000	73.100000	2.410000	4660.000000
75%	62.100000	51.350000	8.600000	58.750000	22800.000000	10.750000	76.800000	3.880000	14050.000000
max	208.000000	200.000000	17.900000	174.000000	125000.000000	104.000000	82.800000	7.490000	105000.000000

Tras una inspección inicial del dataset, se confirma que no existen valores nulos en ninguna de las variables, lo que significa que la preparación de los datos no requiere imputación ni la eliminación de instancias incompletas.

Descripción de los métodos utilizados para la limpieza de datos, preprocesamiento y visualización.

Detección de valores atípicos


Dentro del análisis de los datos, se identifica que 8 países presentan valores negativos en la variable **inflation**: Bahamas, República Checa, Irlanda, Japón, Letonia, Seychelles, Singapur y Eslovenia. Dada la naturaleza económica de este indicador, un valor negativo de inflación corresponde al fenómeno conocido como deflación, que es plausible y documentado en la realidad económica mundial. Por tanto, se decide mantener estos valores sin modificación.

Distribuciones individuales

El análisis de los histogramas con curvas KDE revela que la mayoría de las variables presentan una distribución con asimetría positiva (sesgada a la derecha). Esto implica que la mayor parte de los países se concentra en valores bajos o medios, con una cola larga hacia valores altos. Esta característica es especialmente pronunciada en **gdpp** e **income**, donde una minoría de países con economías muy desarrolladas eleva considerablemente el rango máximo frente a la mediana.

Relaciones entre variables


Mediante un gráfico de pairplot se estudian las relaciones bivariadas entre todas las variables numéricas. Se observa que la mayoría de las relaciones no son estrictamente lineales, destacando casos como la relación entre **gdpp** y **child_mort**, que muestra un patrón exponencial o logarítmico: a medida que el PIB per cápita crece, la mortalidad infantil cae rápidamente hasta estabilizarse en valores muy bajos.



Correlaciones clave

El análisis de la matriz de correlaciones revela las siguientes relaciones más significativas:

- **Correlación positiva fuerte:** income y gdpp (0.90), lo que indica que ambas variables capturan información muy similar sobre la riqueza de un país. También destaca child_mort y total_fer (0.85), reflejando que los países con mayor mortalidad infantil tienden a tener tasas de fertilidad más altas.
- **Correlación negativa fuerte:** child_mort y life_expec (-0.89), evidenciando la relación inversa entre mortalidad infantil y esperanza de vida. También life_expec y total_fer (-0.76).
- **Correlación débil o moderada:** variables como health, imports y exports muestran correlaciones más débiles con el resto, lo que sugiere que aportan información menos redundante al conjunto.



Estas correlaciones son relevantes de cara a la selección de características, dado que variables altamente correlacionadas pueden introducir redundancia en el entrenamiento del SOM, inflando el peso de cierta dimensión del dato sin aportar información nueva.

Necesidad del escalado

Como se ha observado en el estudio de variables, las 9 características numéricas presentan rangos muy dispares. Variables como gdpp abarcan desde 231 hasta 105.000, mientras que total_fer se mueve únicamente entre 1,15 y 7,49. Dado que

el SOM basa su aprendizaje en el cálculo de distancias euclidianas entre los vectores de entrada y los pesos de las neuronas, entrenar con datos sin escalar provocaría que variables con mayor rango numérico dominen completamente el cálculo de distancias, anulando la influencia de las demás.

Método de escalado aplicado

Para el escalado del conjunto de datos se utiliza RobustScaler, el cual transforma cada variable restando su mediana y dividiendo por el rango intercuartílico ($IQR = Q3 - Q1$). A diferencia del StandardScaler, que emplea la media y la desviación estándar, Utilizando RobustScaler, se consigue que todas las variables queden en escalas comparables sin que estos outliers compriman excesivamente la distribución de la mayoría de los países. Esta elección se justifica por la naturaleza del dataset: existen valores atípicos reales y plausibles que no deben ser eliminados, como la deflación en 8 países o los valores extremos en variables como gdp e income.

Dataset resultante

Tras el escalado, el conjunto de datos de entrenamiento queda compuesto por 167 instancias y 9 variables numéricas transformadas, conservando country como etiqueta externa para la identificación de países en los resultados del SOM. Este mismo procedimiento de escalado con RobustScaler se aplicará posteriormente al subconjunto de variables económicas para el entrenamiento del mapa económico.

3. Implementación

La gráfica de la Medida de Divergencia se aplanan mejor empleando valores de ratio de aprendizaje menores, aunque esto se debe a que la tasa de aprendizaje descendiente de la red SOM congela el entrenamiento en cierto punto, haciendo que las predicciones se estanquen y dando la falsa sensación de aplanamiento. Un valor que tiene mayor sentido dentro del contexto sería 0.5.

El radio de vecindad se establece como la mitad de la dimensión más baja, permitiendo ajustarlo en función de la red que se esté entrenando, dado que no tiene sentido mantener el mismo radio en una red 2x2 que en una 8x8.

Tras explorar el conjunto de posibles combinaciones de dimensionalidad en [2, 4, 6, 8, 10, 12], descartamos los valores superiores a 8, ya que generan redes con prácticamente una neurona por dato, lo cual no es óptimo teniendo en cuenta que hay combinaciones menores que dan resultados iguales o mejores. Aplicando además la heurística $5 \times \sqrt{N}$, el rango queda acotado entre 2 y 7. Combinando ambas observaciones y descartando los valores bajos de dimensionalidad, el espacio de prueba óptimo resulta ser [4, 5, 6, 7].

Las métricas de evaluación empleadas son tres: el Error de Cuantización, que mide la distancia media entre cada dato y su neurona ganadora (BMU); el Error Topográfico, que evalúa si la red se ajusta correctamente al conjunto de datos, fijando un umbral de descarte en 0.15; y la Medida de Divergencia, donde no se buscan valores bajos, sino que esta se aplane progresivamente a lo largo del entrenamiento, lo que indicaría un ajuste óptimo de la red.

Tras aplicar la regla de que el radio de vecindad fuese el valor de la dimensión máxima dividido entre 2, la Medida de Divergencia de todas las redes entrenadas empezó a divergir en mayor medida con respecto a las pruebas iniciales donde se mantenía el radio en 1. Los errores topográficos y de cuantización se mantuvieron en esencia con el mismo comportamiento, salvo el error topográfico, que empezó a presentar más saltos de valores a lo largo de las épocas. Por otro lado, las redes con estructura rectangular, típicamente de columna, presentaron una menor divergencia en las últimas épocas, aunque sin llegar a converger en un valor determinado, lo que genera dudas sobre la efectividad real de este ajuste del radio de vecindad.

Para la selección del modelo final, además de las métricas se realiza una comparativa visual entre las 3 mejores configuraciones, analizando la agrupación de países por neurona, la frontera entre grupos a través de la U-Matrix y el número de neuronas muertas o inactivas. Con el fin de estudiar esto, se emplea un mapa de calor sobre la red ya entrenada, el cual también permite observar los valores finales de los pesos con respecto a cada variable, pudiendo identificar las neuronas más influyentes en la clasificación y descubrir posibles relaciones no lineales entre variables cuando distintas neuronas presentan patrones de pesos similares.

Entre los modelos resultantes con tasa de aprendizaje 0.5 y 2000 iteraciones, destacan:

- **[6x6]:** segunda mejor marca en error de cuantización, menos neuronas muertas que el resto y agrupación más uniforme.
- **[7x7]:** mejor error de cuantización, pero peor marca en el error topológico, con 4 neuronas muertas y una neurona que aglomera notoriamente más países que las demás.
- **[6x7] y [7x6]:** de manera coincidente, presentan la misma frontera en la U-Matrix y el mismo número de neuronas muertas (4), aunque con una distribución más equilibrada que la 7x7 al no presentar neuronas que concentren un número desproporcionado de países.
- **[5x5]:** sin neuronas muertas, aunque con un error de cuantización ligeramente peor. La frontera en la U-Matrix tiene una forma similar al resto de configuraciones cuadradas, aunque con mayor tendencia a forma de columna.

El modelo seleccionado como óptimo es **[6x6]**, por ser el más equilibrado entre todas las métricas evaluadas.

4. Evaluación


4.1 Identificar los grupos que aparecen en el modelo, describirlos y marcarlos en el mapa de activación.

Dado el entrenamiento de la red neuronal SOM, los resultados indican un conjunto de grupos los cuales acaban clasificando de manera indirecta los diferentes países presentes dentro del conjunto de datos. Sin embargo, el número de grupos resultante será el equivalente al conjunto de neuronas activas dentro de la red neuronal SOM entrenada y empleada para la inspección.

Esto último carece de sentido contextual, dado que no hay forma de que realicemos una clasificación tan pequeña dentro del conjunto total de datos empleados. Dado que tenemos unos 169 países, debemos de pensar que hay formas más acordes de agrupar los países. Una forma de verlo es a través de la considerada forma socioeconómica de clasificarlos, que es en: "Primer mundo", "Tercer Mundo" y "Segundo Mundo" (aunque este término no es del todo usado). Otro número lógico de agrupaciones que podrían realizarse sería entorno a valores y grupos de mayor tamaño y menos cantidad de grupos, como lo pueden ser en 5 clústeres distintos o 4.

Para ello, utilizamos una técnica de agrupamiento en función de la propia red SOM calculada, donde agrupamos a aquellos países pertenecientes a neuronas las cuales se encuentran cerca o a "poca distancia", de esta forma, vamos agrupando aquellas neuronas que pueden llegar a tener menor número de países pero que a su vez se encuentran cerca de otras neuronas que pueden tener similitudes en su contexto y datos, debido al cálculo de la distancia entre neuronas.

Por lo tanto, lo que acabamos realizando es una reducción de las dimensiones propias de la red neuronal SOM, y a raíz de ahí calcular a través de distancias (como lo puede ser el uso de KMeans), para sacar clústers más grandes de países.



Como podemos apreciar, la clasificación de estos grupos resultantes dentro de la red SOM tras aglomerar las neuronas más cercanas entre sí, da como resultado una vista bastante clara de una segmentación de los distintos grupos de países en función de sus características socioeconómicas, de forma que podemos apreciar como los grandes grupos resultantes dan como resultado una clasificación en donde se nota una gran diferencia de los valores.


En concreto, si realizamos una clasificación en 5 grupos podemos observar que los grupos se diferencian entre sí dando como resultado a macro-grupos donde se encajan los países con una situación similar. Además, vemos que la distinción es clara, teniendo: el [G0] una tasa de mortalidad infantil medio, en relación con una serie de variables económicas que dan a entender una posición "media-baja"; el [G1] una tasa de mortalidad mucho más baja, de hecho, la menor, donde destacamos que es con diferencia el conjunto de países más rico, teniendo también una esperanza de vida muy alta y la tasa de fertilidad baja, siendo todo estos claros indicativos de un conjunto de países de "Primer Mundo"; el [G2] es con diferencia la agrupación de países más pobres y con peor posición socioeconómica, dado que presentan la mayor tasa de mortalidad infantil en relación con también unos muy bajos valores en el apartado económico; el [G3] está conformado por un conjunto de países que se encuentran en un "limbo", donde no se les puede considerar como países pobres pero no tienen la prosperidad de los países del Primer Mundo; el [G4] realmente es un conjunto de países con una situación económica parecida a la del G0, sin embargo, estos presentan valores sociales mucho peores, como por ejemplo la tasa de mortalidad infantil.

4.2. Evaluar qué indicadores demográficos, económicos, geográficos y/o de desarrollo son los principales impulsores detrás de la formación de estos clústeres.

Para poder explorar los distintos grupos que se dan como resultado del agrupamiento de las distintas neuronas en "clústeres" de países, debemos de inspeccionar que efecto realizan sobre los países que están comprendidos dentro de cada clúster. De esta forma, a través de un mapa de correlaciones aplicado

entre las variables del dataset original con respecto a cada clúster resultante, podemos observar que afecta más en concreto a cada grupo de países resultante del anterior punto.

De esta manera pretendemos entender que agrupación se realiza, basándonos en el anterior punto y las observaciones de la correlación calculada.



Viendo como se ha distribuido el conjunto de grupos resultantes en relación con las variables, podemos proseguir con una explicación propia de cada uno de los grupos y que destaca, de manera positiva y negativa, dentro de cada uno de ellos.


Los indicadores demográficos y socio económicos propios del dataset que influyen en mayor medida, de forma negativa o positiva, a cada uno de los clústers va variando, dependiendo de que grupo de países estemos analizando. De manera más específica podemos hablar de:


- [G0]: el grupo 0 es claramente el grupo de países más afectados de manera negativa por cada uno de los valores tanto demográficos como económicos, indicando que los análisis previos tenían sentido, asumiendo que este grupo de países es en efecto aquellos que podemos considerar como pobres. De entre las variables visibles que influyen, podemos destacar que hay una clara influencia negativa de la importación por debajo incluso de valores más impactantes con lo pueden ser el de la mortalidad infantil o la salud.
- [G1]: el grupo 1 es bastante influenciado de manera positiva por los valores tanto económicos como demográficos, teniendo una correlación lineal directa con estos valores. Podemos destacar de entre todas las variables que encontramos las variables económicas, las cuales tienen en concreto una correlación positiva más fuerte que el resto de las variables, siendo las únicas que destacan aparte de estas la salud y la esperanza de vida. Observando entonces tanto los valores como la influencia de las variables en dicha tendencia positiva, podemos afirmar que el análisis previo donde se cataloga a este grupo como el conjunto de países de Primer Mundo o ricos es correcto.

- [G2]: el grupo 2 comprende al conjunto de países más pobres que podemos tener dentro de nuestro dataset, debido a que, si analizamos la influencia de las variables dentro del conjunto de países, podemos ver que el grupo es directamente proporcional con la mortalidad infantil y con la tasa de fertilidad, siendo además inversamente proporcional (correlación negativa) con las variables económicas y, sobre todo, con la esperanza de vida. De esta manera, podemos comprender que este conjunto de países, como se analizó previamente, comprende el conjunto de países que se encuentran en situaciones socioeconómicas precarias, siendo en esencia los países considerados como Tercer Mundo.
- [G3]: el grupo 3 comprende el conjunto de países que mantienen una serie de correlaciones con las variables económicas y demográficas de manera más neutral, siendo el único indicativo resaltable la variable de las importaciones. Esto, aunque no indica nada sustancial, puede apoyar la idea debido a las proporciones manejadas que este grupo de países corresponde con el conjunto de ellos que se reconoce como "economías emergentes".
- [G4]: el grupo 4, a pesar de las correlaciones propias que podrían observarse solo con la inspección de los valores medios del clúster, este resalta dado que la variable más influyente (correlación positiva fuerte) es la inflación. Luego dentro de este grupo, podemos acuñar a los países pertenecientes como "países con alta inflación".

4.3. Mapas de agrupación

Agrupación Socioeconómica Mundial (Red Neuronal SOM)





4.4. Clasificar las siguientes instancias

4.4.1. ¿Por qué están posicionados más lejos o más cerca de los centros de los grupos en los que fueron clasificados?

Para poder inspeccionar que tan cerca o lejos se encuentran los países determinados dentro del enunciado, primero debemos de inspeccionar que neuronas son las que acaban agrupando a cada uno de los países. Primero, debemos de calcular la distancia que existe como tal entre la BMU de cada país con los valores de este. Una vez inspeccionado esto, entonces podemos calificar cuanto de lejano es cada país con respecto a su neurona, y por ende con respecto al resto de países clasificados igual que él.

Posterior a esto, podemos realizar el mismo conjunto de cálculos y de observaciones, pero con el clúster asociado, resultante de los apartados previos, para poder analizar de manera más profunda si cada uno de estos países es, en esencia, un "outlier" o valor atípico dentro del contexto de los países, o con respecto al clúster en el que se encuentra cada uno clasificado.

Sabiendo que la medida del error de cuantización de la red SOM entrenada es entorno a un 1.2-1.3, podemos ver que tanto Chile como Botswana presentan distancias incluso menores a la media. Sin embargo, a diferencia de las otras dos, el país de Vietnam se encuentra más alejado de su BMU que la propia media de la red SOM. Esto significa que, probablemente, este país sea realmente un outlier en alguna de las categorías económicas o demográficas, dado que se encuentra más alejado de lo que debería de su propia neurona que mejor encaja con sus valores, siendo entonces incluso más lejano aún al resto de neuronas.

Datos originales de los 6 países en la neurona (4, 5):

	country	child_mort	exports	health	imports	income	inflation	life_expec	total_fer	gdpp	Macro.Grupo
14	Belarus	5.5	51.4	5.61	64.5	16200	15.10	70.4	1.49	6030	Grupo 3
16	Belize	18.8	58.2	5.20	57.5	7880	1.14	71.4	2.71	4340	Grupo 3
148	Thailand	14.9	66.5	3.88	60.8	13500	4.08	76.6	1.55	5080	Grupo 3
152	Tunisia	17.4	50.5	6.21	55.3	10400	3.82	76.9	2.14	4140	Grupo 3
154	Turkmenistan	62.0	76.3	2.50	44.5	9940	2.31	67.9	2.83	4440	Grupo 3
164	Vietnam	23.3	72.0	6.84	80.2	4490	12.10	73.1	1.95	1310	Grupo 3

Media de los indicadores para este grupo específico:

	child_mort	exports	health	imports	income	inflation	life_expec	total_fer	gdpp
mean	23.65	62.483333	5.04	60.466667	10401.666667	6.425	72.716667	2.111667	4223.333333
min	5.50	50.500000	2.50	44.500000	4490.000000	1.140	67.900000	1.490000	1310.000000
max	62.00	76.300000	6.84	80.200000	16200.000000	15.100	76.900000	2.830000	6030.000000


Si vemos con más detalle el conjunto de países que se encuentran dentro de la misma neurona, clasificados junto a Vietnam, podemos observar que la diferencia más significativa entre Vietnam y el resto de países es que la relación de las variables económicas y demográficas dentro de Vietnam no siguen un patrón para nada claro, sobre todo en comparativa con países como 'Belarus' o 'Belize', donde se puede ver que los valores de las variables económicas son proporcionales a otro tipo de variables como la de mortalidad infantil, o que, por ejemplo, el conjunto de variables económicas siguen una tendencia donde los ingresos acompañan al PIB. Sin embargo, dentro de Vietnam podemos ver como no sigue este patrón, dado que tienen variables económicas como exports e imports bastante altas, pero el PIB proporcionalmente muy menor con respecto al resto.

4.4.2. ¿Cómo se relacionan con los grupos circundantes en términos de proximidad topológica?

Tras analizar la U-Matrix y la disposición de los países en nuestra red, podemos ver cómo la proximidad en el mapa refleja realmente la similitud en los datos de origen. Al observar a los tres países seleccionados, su relación con el entorno varía según la homogeneidad de su zona:

- **Chile:** es el caso más llamativo visualmente. Se encuentra justo encima de una de las franjas más oscuras y negras del mapa. Como en un SOM el negro representa una distancia estadística muy grande, esto nos indica que Chile, aunque esté cerca de otras neuronas en el dibujo, tiene una proximidad topográfica muy baja con los grupos que tiene a su izquierda. Actúa como un "país frontera": marca el límite donde terminan los países en desarrollo y empiezan los grupos de rentas altas, funcionando como un muro de separación entre ambos perfiles.
- **Vietnam:** está en una zona de colores mucho más claros y uniformes. Esto significa que su relación con los vecinos es muy fluida. Su perfil socioeconómico no da saltos bruscos respecto a las neuronas de al lado, lo que sugiere que está bien integrado en un clúster de países con indicadores muy parecidos y estables.
- **Botswana:** aunque también está en una zona clara, se ve que está cerca de un gradiente que empieza a oscurecerse. Esto lo sitúa como un país con una


relación equilibrada: está integrado en su grupo local, pero a muy poca distancia de empezar a diferenciarse de los bloques vecinos.



4.4.3. ¿Cuál crees que debería ser el criterio de agrupamiento representado por el mapa?

Para poder responder a esta pregunta hemos no solo los resultados mostrados por el modelo, sino que también hemos tenido que analizarlo nosotros como ingenieros informáticos. El mapa debería ser el nivel de desarrollo socioeconómico de cada país. El SOM hace agrupaciones de los países según su similitud en variables como el PIB, mortalidad infantil, tasa de fertilidad e indicadores como comercio exterior, que como conjunto llegan a mostrar el grado de desarrollo de una nación.

Los clústeres tienden a coincidir con las grandes regiones del mundo según su nivel de desarrollo. Podemos poner los ejemplos de que países estas más desarrollados después de hacer el estudio




4.4.4. Identificar los países que aparecen como valores atípicos o que están posicionados en las regiones más aisladas del mapa.

Para poder considerar a un país como valor atípico debemos de tener en cuenta el conjunto de valores medios, mediana y cuartiles propios de cada una de las variables tanto económicas como demográficas del propio conjunto de datos. De esta forma inspeccionamos cómo se comportan los países y que datos tienen en comparación con estas variables estadísticas.

Para poder explorar en que posición dentro del mapa del conjunto de datos totales se encuentran dichos países, graficamos el conjunto al total y resaltamos aquellos

países que se encuentren más alejados con respecto a la neurona donde están clasificados (BMU). Si mantenemos un análisis de los 5 países más alejados, es decir, con el mayor valor dentro del Error de Cuantización, podemos observar los patrones que corresponden a cada uno de los países en concreto.



Dentro de los 5 países más alejados con respecto a sus BMUs encontramos a: Nigeria, Luxemburgo, Singapur, Malta y Qatar. Cada uno de los países mencionados tienen una distancia alta con respecto a los clústeres y neuronas donde se encuentran debido a diversas razones. Si quisiésemos sacar conclusiones globales y no particulares encontraríamos complicaciones, debido a que no mantienen una homogeneidad en su diferencia, no siguen un patrón común.

Country	Child_mort	exports	health	imports	income
Luxemburgo	2.8	175.0	7.77	142.0	91700
Malta	6.8	153.0	8.65	154.0	28300
Nigeria	130.0	25.3	5.07	17.4	5150
Qatar	9.0	62.3	1.81	23.8	125000
Singapore	2.8	200-0	3.96	174.0	72100

Country	inflation	life_expec	total_fer	gdpp	Macro_Grupo
Luxemburgo	3.620	81.3	1.63	105000	Grupo 1
Malta	3.830	80.3	1.36	21100	Grupo 3
Nigeria	104.000	60.5	5.84	2330	Grupo 4
Qatar	6.980	79.5	2.07	70300	Grupo 1
Singapore	-0.046	82.7	1.15	46600	Grupo 1

Se puede observar que Luxemburgo, Qatar y Singapur mantienen una situación económica excelsa, superando con creces la media del conjunto de datos y siendo outliers en atributos como 'imports', 'income' o 'gdpp', es decir, el conjunto más importante de variables económicas. Tanto es así que, a pesar de pertenecer al grupo de países ricos (Grupo 1), aun así, destacan por encima de las medias previamente visualizadas de cada uno de los clústeres resultantes.

Sin embargo, este no es el mismo caso para otros países como Malta o Nigeria, donde las razones por las que se consideran como outliers son bastante distintas. En concreto, Nigeria es un outlier masivo dentro del atributo de 'child_mort', haciendo que destaque por encima del resto de países en dicha categoría. Otro punto donde Nigeria se convierte en outlier es en la variable de 'inflation', donde su valor 130.0 es correspondiente a unas 13 veces el valor medio de dicha variable dentro del dataset total.

Por último, encontramos que el país de Malta mantiene unos valores que, si bien no son próximos a los valores cercanos a la mediana o media de su grupo o del dataset global, simplemente presenta un conjunto de inconsistencias a lo largo de los valores los cuales se separan de dichos valores propios del clúster y hacen que como resultado su error de cuantización sea notoriamente superior al del resto de países dentro de la neurona.

Estas condiciones particulares de diversos países hacen que se resalten situaciones socioeconómicas únicas, como es el caso del país de Luxemburgo, el cual mantiene una posición de privilegio económico incluso superior a la gran mayoría de países que están agrupado dentro del previamente explicado grupo del "Primer Mundo". Esto ayuda a exponer de cierta forma aquellos países "especiales" por su situación fiscal/económica (Singapur, Luxemburgo, Qatar), así como aquellos que se encuentran separados del resto por otras razones, como la demográfica (Nigeria).

5. Conclusiones

A partir del modelo 6×6 seleccionado, hemos podido distinguir 5 grupos de países que reflejan las diferencias reales de desarrollo a nivel mundial, coincidiendo con las categorías tradicionales.

Los indicadores con mayor poder discriminante han resultado ser la mortalidad infantil, el PIB per cápita, el ingreso neto y la esperanza de vida, que juntos resumen de forma compacta la situación socioeconómica de un país. Variables como las exportaciones e importaciones han mostrado una influencia más moderada pero relevante en grupos concretos, como el G3 (economías emergentes) y G4 (alta inflación).

El análisis de valores atípicos ha puesto de manifiesto que ciertos países — Luxemburgo, Singapur y Qatar por su riqueza extrema, y Nigeria por su mortalidad infantil e inflación excepcionalmente altas— no encajan perfectamente en ningún clúster, lo que refleja situaciones socioeconómicas genuinamente singulares que los modelos de agrupamiento estándar tienen dificultades para capturar.

En definitiva, el SOM ha demostrado ser una herramienta de visualización y clustering poderosa para datos multidimensionales, permitiendo extraer interpretaciones significativas sin necesidad de etiquetas previas.

6. Referencias

- [1] JustGlowing, 24 Apr 2021. [En línea]. Available: <https://github.com/JustGlowing/minisom>.
- [2] 7 Jan 2018. [En línea]. Available: <https://numpy.org/>.
- [3] Matplotlib, 2012. [En línea]. Available: <https://matplotlib.org/>.
- [4] 2012. [En línea]. Available: <https://seaborn.pydata.org/>.